

UNIVERZITA KOMENSKÉHO V BRATISLAVE  
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

GENEROVANIE REALIZÁCIÍ ROVNOMERNÉHO  
ROZDELENIA PRAVDEPODOBNOSTI NA  
MNOHOROZMERNÝCH POLYÉDROCH  
BAKALÁRSKA PRÁCA

2018  
SLAVOMÍR HANZELY



UNIVERZITA KOMENSKÉHO V BRATISLAVE  
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

GENEROVANIE REALIZÁCIÍ ROVNOMERNÉHO  
ROZDELENIA PRAVDEPODOBNOSTI NA  
MNOHOROZMERNÝCH POLYÉDROCH  
BAKALÁRSKA PRÁCA

Študijný program: Informatika  
Študijný odbor: Informatika  
Školiace pracovisko: Katedra aplikovanej matematiky a štatistiky  
Školiteľ: doc. Mgr. Radoslav Harman, PhD.

Bratislava, 2018  
Slavomír Hanzely





Univerzita Komenského v Bratislave  
Fakulta matematiky, fyziky a informatiky

## ZADANIE ZÁVEREČNEJ PRÁCE

**Meno a priezvisko študenta:** Slavomír Hanzely  
**Študijný program:** informatika (Jednoodborové štúdium, bakalársky I. st., denná forma)  
**Študijný odbor:** informatika  
**Typ záverečnej práce:** bakalárska  
**Jazyk záverečnej práce:** slovenský  
**Sekundárny jazyk:** anglický

**Názov:** Generovanie realizácií rovnomerného rozdelenia pravdepodobnosti na mnohorozmerných polyédroch

*Random sampling from the uniform distribution on multidimensional polyhedra*

**Anotácia:** V Monte-Carlo metódach výpočtu pravdepodobností a v znáhodnených optimalizačných metódach je často potrebné generovať realizácie z rovnomerného rozdelenia na mnohorozmerných polyédroch. Tieto polyédre môžu byť zadane buď systémom konečného počtu lineárnych nerovníc (takzvaná H-reprezentácia), alebo ako konvexný obal konečnej množiny bodov (takzvaná V-reprezentácia). V prípade oboch typov reprezentácií je rovnomerné generovanie vo vnútri všeobecného polyédra netriviálna úloha, kombinujúca techniky a poznatky z matematiky, štatistiky a informatiky.

**Cieľ:** Cieľom bakalárskej práce je: Po prvé vypracovať prehľad existujúcich prístupov generovania realizácií z rovnomerného rozdelenia na polyédroch (priame generovanie pre špeciálne polyédre, zamietacie algoritmy, MCMC algoritmy a iné); po druhé vypracovať a programovo implementovať vlastnú metódu založenú na elipsoide najmenšieho objemu obsahujúceho zadaný polyéder.

**Vedúci:** doc. Mgr. Radoslav Harman, PhD.  
**Katedra:** FMFI.KAMŠ - Katedra aplikovanej matematiky a štatistiky  
**Vedúci katedry:** prof. RNDr. Daniel Ševčovič, DrSc.  
**Dátum zadania:** 14.10.2018

**Dátum schválenia:** 24.10.2018

doc. RNDr. Daniel Olejár, PhD.  
garant študijného programu

.....  
študent

.....  
vedúci práce



**Pod'akovanie:**

# Abstrakt

**Klíčové slova:**



# Abstract

Keywords:



# Obsah

<b>Úvod</b>	<b>1</b>
<b>1 Zamietacie metódy</b>	<b>3</b>
1.1 Použitie na generovanie bodu vnútri polyédru . . . . .	4
<b>2 Metropolis-Hastings algoritmus</b>	<b>5</b>
<b>3 Gibbsov generátor</b>	<b>7</b>



# Úvod

V rámci tejto práce sa budeme zaoberať metódami na rovnomerné generovanie bodov vo veľarozmernom polyédre (konvexnom mnohostene). Našou úlohou vytvoriť generátor, ktorý bude čo najrýchlejšie generovať body vnútri polyédru rovnomerne náhodne, tj. pravdepodobnosť, že dostaneme bod vnútri ľubovoľnej oblasti polyédra je iba lineárne závislá od objemu danej časti.

Ako základ náhody bude používať náš generátor bodu v polyédre používať rovnomerný generátor čísel  $[0, 1]$ . Pomocou generátoru na  $[0, 1]$  možno triviálne generovať bod na  $[0, k]$  (prenásobením konštantou  $k$ ), tiež možno generovať bod na  $[a, b]$  (vygenerovaním bodu na  $[0, -a + b]$  a pripočítaním  $a$ ), alebo bod na  $[0, 1]^n$  (postupným vygenerovaním súradníc).

Vo všeobecnosti možno polyéder reprezentovať viacerými spôsobmi, napríklad ako konvexný obal bodov alebo ako sústavu lineárnych nerovníc. Obidve spomenuté reprezentácie možno previesť na tú druhú, avšak prevod medzi nimi nie je lacný. Pre účely tejto práce budeme pracovať s polyédrom reprezentovaným sústavou lineárnych nerovníc, riešení systému  $Ax \leq b$  ( $x \in X$  ak  $Ax \leq b$ ).

Začneme zamietacími metódami.

**TODO** prechod medzi metodami



# Kapitola 1

## Zamietacie metódy

Zamietacie metódy nám poskytujú jeden zo spôsobov rovnomerného generovania bodov na určitej množine. Myšlienka za nimi je nasledovná: Označme si  $X$  množinu, na ktorej chceme rovnomerne náhodne generovať prvky. Predpokladajme, že nevieme priamo rovnomerne generovať body na  $X$ , no vieme rovnomerne generovať na množine  $S$ ,  $X \subset S$ .

Náš generátor  $G_z$  bude pracovať nasledovne:

---

**Algorithm 1** Zamietacia metóda

---

- 1: **repeat** Vygeneruj bod  $x \in S$  rovnomerne náhodne
  - 2: **until**  $x \in X$
  - 3: Vráť bod  $x$  ako vygenerovaný bod
- 

Generátor  $G_z$  vygeneruje bod  $x \in S$ , ak je ten bod aj z  $X$ , tak ho vráti ako výstup, inak vygeneruje nový bod  $x \in S$ .

Generátor  $G_z$  generuje na  $X$  rovnomerne náhodne. Očakávaná rýchlosť generovania závisí od toho, koľkokrát  $G_z$  vygeneruje bod mimo  $X$ . Z rovnomernosti  $G_z$  je tá pravdepodobnosť rovná  $\frac{|S-X|}{|S|} = 1 - \frac{|X|}{|S|}$ . Označme si  $p_k$  pravdepodobnosť, že  $G_z$  bude generovať bod z  $S$   $k$ -krát. Platí  $p_k = (1 - \frac{|X|}{|S|})^{k-1} \frac{|X|}{|S|}$ . Očakávaný počet generovaní  $G_z$  je  $E(G_z) = \sum_0^\infty k p_k = \frac{|X|}{|S|} \sum_0^\infty k (1 - \frac{|X|}{|S|})^{k-1}$ .

Táto metóda generovania je vhodná, ak je  $\frac{|X|}{|S|}$  dosť veľké, tj. ak je obal  $S$  polyédru  $X$  dostatočne malý. Ak je  $\frac{|X|}{|S|} \sim 0$ , tak je táto metóda nepoužiteľná.

**TODO citovať**

## 1.1 Použitie na generovanie bodu vnútri polyédru

Zamyslime sa nad tým, ako by sme vedeli použiť túto metódu na generovanie bodu vnútri polyédru. Ako množinu možných  $S$ ,  $X \subset S$  môžeme použiť najmenší kváder so stranami rovnobežnými s osami. Vypočítať súradnice kvádra je ľahké, stačí nám to spraviť raz pred (začatím generovania) pomocou lineárneho programovania.

Žiaľ pre takúto množinu  $S$  môže byť podiel  $\frac{|X|}{|S|}$  byť ľubovoľne malý. Ak bude  $X$  kváder s obsahom  $k$  pozdĺž diagonály kocky  $[0, 1]^n$ , dotýkajúci sa každej steny kocky  $[0, 1]^n$ , tak najmenšia množina  $S$  (kváder so stranami rovnobežnými s osami) je kocka  $[0, 1]^n$ , ktorá má obsah 1. Platí  $\frac{|X|}{|S|} = k$ . Keďže vieme nájsť kváder taký, že  $k$  je ľubovoľne malé, tak očakávaná dĺžka generovania touto metódou (pre danú množinu  $S$ ) je ľubovoľne veľká.

V rámci tejto práce budeme skúmať použitie problému obalenia polyédru elipsoidom s najmenším obsahom (Minimum Volume Enclosing Elipsoid, ďalej MVEE). Ako množinu  $S$  zvolíme nájdený elipsoid. Generovať body v ňom rovnomerne náhodne vieme ľahko **TODO zdôvodniť**.

Taktiež sa pokúsime pomocou hlavných osí MVEE elipsoidu obaliť polyéder kvádom s najmenším obsahom (jeho strany nemusia byť rovnobežné s osami sústavi). Ako množinu  $S$  môžeme zvoliť daný kváder.



## Kapitola 2

# Metropolis-Hastings algoritmus

V tejto kapitole sa budeme zaoberať Metropolis-Hastings algoritmom na generovanie bodov z ľubovoľnej distribúcie.

Majme cieľnú hustotu  $Q$  z ktorej chceme generovať, v našom prípade je rovnomerná vnútri polyédru a nulová mimo neho. Metropolis-Hastings algoritmus je vždy v stave  $x^{(i)}$  reprezentovanom bodom v priestore, stav určuje hustotu  $Q(x^{(i)})$  závislú na  $x^{(i)}$ . Algoritmus vygeneruje ďalší potenciálny stav  $y$  podľa hustoty  $Q(x^{(i)})$ . Ďalší stav algoritmu  $x^{(i+1)}$  bude  $y$  s pravdepodobnosťou  $\alpha(x^{(i)}, y)$ , inak to bude  $x^{(i)}$ .

---

**Algorithm 2** Metropolis-Hastings [2]

---

```
1: inicializuj  $x^{(0)}$ 
2: for  $i = 0, 1, \dots, N$  do
3:   Vygeneruj bod  $y$  z  $Q(x^{(i)})$ 
4:   Vygeneruj  $u$  z  $U(0, 1)$ .
5:   if  $u \leq \alpha(x^{(i)}, y)$  then
6:     Nastav  $x^{(i+1)} = y$ 
7:   else
8:     Nastav  $x^{(i+1)} = x^{(i)}$ 
9: Vráť  $x^{(1)}, x^{(2)}, \dots, x^{(N)}$ .
```

---

Môžeme si všimnúť, že v Metropolis-Hastings algoritme je bod  $x^{(i)}$  závislý od predchádzajúceho bodu  $x^{(i-1)}$ . Podľa [2] je možné dokázať, že pre dostatočne veľké  $N$  budú body  $x^{(1)}, x^{(2)}, \dots, x^{(N)}$  z hustoty  $Q$ .

**TODO** Ake veľke  $N$ ?

**TODO** Všeobecnejšie Monte Carlo Markov Chain metody - Metropolis algoritmus ako špeciálny prípad

**TODO** voľba parametrov

**TODO** praktické využitie

**TODO** exaktný algoritmus na generovanie v polyedri



# Kapitola 3

## Gibbsov generátor

V tejto kapitole sa budeme zaoberať Gibbsovým generátorom, metódou generovania z triedy MCMC vhodnou na generovanie vo viacrozmernom priestore. Na Gibbsov generátor sa možno dívať ako na špeciálny prípad Metropolis-Hastings algoritmu.

Našou úlohou je generovať z  $K$ -rozmernej distribúcie  $Q$ , pričom z  $Q$  nevieme generovať priamo. Predpokladajme, že nevieme použiť priamo Metropolis-Hastings algoritmus, lebo  $Q(x^{(i)}) = Q(x_1^{(i)}, x_2^{(i)}, \dots, x_K^{(i)})$  je príliš zložitá na generovanie. Taktiež predpokladajme, že ak  $Q(x^{(i)})$  obmedzíme na jeden rozmer, tak v ňom vieme generovať rýchlo, tj. možno generovať rýchlo z  $Q(x_j^{(i)} | x_1^{(i+1)}, x_2^{(i+1)}, \dots, x_{j-1}^{(i+1)}, x_{j+1}^{(i)}, x_{j+2}^{(i)}, \dots, x_K^{(i)})$ .

Gibbsov generátor bude fungovať nasledovne:

---

**Algorithm 3** Gibbsov generátor [5]

---

```
1: inicializu  $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_K^{(0)})$ 
2: for  $i = 1, \dots, N$  do
3:   for  $j = 0, 1, \dots, K$  do
4:      $x_j^{(i)} \sim Q(x_j | x_1^{(i+1)}, x_2^{(i+1)}, \dots, x_{j-1}^{(i+1)}, x_{j+1}^{(i)}, x_{j+2}^{(i)}, \dots, x_K^{(i)})$ 
5:    $x^{(i+1)} = (x_1^{(i+1)}, x_2^{(i+1)}, \dots, x_K^{(i+1)})$ 
6: Vráť  $x^{(1)}, x^{(2)}, \dots, x^{(N)}$ .
```

---

Gibbsov generátor ako špeciálny prípad Metropolis-Hastings algoritmu má podobné vlastnosti ako Metropolis-Hastings algoritmus.

**TODO** rozdiely s MH menej parametrov

**TODO** prakticke vyuzitie

**TODO** vyuzitie pri polyedroch



# Literatúra

- [1] Ming-Hui Chen and Bruce W. Schmeiser. General Hit-and-Run Monte Carlo sampling for evaluating multidimensional integrals. *Operations Research Letters*, 19(4):161–169, October 1996.
- [2] Siddhartha Chib and Edward Greenberg. Understanding the Metropolis-Hastings Algorithm. *The American Statistician*, 49(4):327–335, November 1995.
- [3] Radoslav Harman, Lenka Filová, and Peter Richtárik. A Randomized Exchange Algorithm for Computing Optimal Approximate Designs of Experiments. *arXiv:1801.05661 [stat]*, January 2018. arXiv: 1801.05661.
- [4] Radoslav Harman and Vladimír Lacko. On decompositional algorithms for uniform sampling from n-spheres and n-balls. *Journal of Multivariate Analysis*, 101(10):2297–2304, November 2010.
- [5] D. J. C. Mackay. Introduction to Monte Carlo Methods. In Michael I. Jordan, editor, *Learning in Graphical Models*, NATO ASI Series, pages 175–204. Springer Netherlands, Dordrecht, 1998.